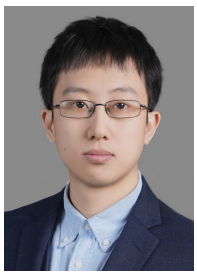
赵健鑫 Jianxin Zhao

AI 系统研发 · 推理优化与计算框架



剑桥大学计算机博士 | 2016 年起从事数值计算与 AI 系统研发
电话 / 微信：+86-18813185627 | 邮箱：603656914@qq.com
主页：jianxin.ocaml.xyz | GitHub：github.com/jzstark | LinkedIn：linkedin.com/in/jzstark
求职意向：AI 推理系统 / AI 框架研发 | 期望城市：北京 / 上海 / 杭州 / 深圳
到岗时间：可 1 个月内回国到岗（可协商） | 支持线上面试

个人优势

- **推理系统：**面向车端实时推理，主导基于 VLM/VLA 的自动驾驶大模型推理系统研究 OverDrive；完成 4 个开源驾驶大模型的执行剖析，阶段级实验中输入准备与视觉编码用时降低 38.5%。
- **计算框架：**开源科学计算与深度学习框架 Owl 的核心开发者、项目负责人（2017 年起），参与设计计算图抽象，主导图级内存优化与 ONNX 模型导出；使经典图像分割网络 Mask R-CNN 的 CPU 推理内存降低 86.6%。
- **科研与落地：**25+ 篇论文（7 篇 CCF-A），4 部英文专著（出版社：Wiley、Springer、Apress）；多项国家级科研项目核心骨干；交付过港口实时预测与律所知识库 Agent 系统。

核心项目与工作经历

卡尔斯鲁厄理工学院（KIT，德国） 2023.10–2026.10
博士后研究员（合作导师：Alexey Vinel 教授）· 自动驾驶 AI 系统

- **OverDrive：车载 VLM/VLA 推理系统（主导）**
  - **研究问题：**面向驾驶场景动态变化的时延要求（SLO），研究车载大模型的推理调度，提升规划结果的及时可用性；负载为 4 个开源驾驶大模型（基于 Qwen2.5-VL、InternVL2、LLaVA 等底座）。
  - **已完成：**主导搭建跨模型执行测量平台（18.5 万次推理采样、8,652 次 CARLA 参考控制器仿真）；用 Nsight Systems / Nsight Compute 做 GPU 时间线与 kernel 级剖析，分析 KV cache、显存带宽与算力瓶颈；评估 GPU 上跨帧与算子级并发；在 RTX 4090 实验平台上将输入准备与视觉编码流水重叠，在阶段级配对实验中相应用时降低 38.5%。
  - **在研：**GPU 算子级并行流水线，以及基于仿真器的端到端评测。
- **专著：**以第一作者撰写 *Autonomous Driving: Technology, Business, and Regulation*（Wiley，2026 年 10 月出版，BMW 集团专家作序）。
- **产业合作（Covadonga，德国）：**为莱茵河多个内河港口的监测系统开发水位实时预测模块，已在线运行。
- 参与德国联邦交通部项目 C2CBridge 2（城乡互联自动驾驶出行）；参与讲授两门自动驾驶方向硕士课程。

Owl：OCaml 科学计算与深度学习框架（开源） 核心开发者 · 项目负责人 2017–至今
Owl 是 OCaml 生态中计算密集型任务的事实标准库（对标 NumPy + SciPy + PyTorch，代码库约 23.6 万行），被量化金融等领域的公司采用。自 2017 年起，在博士及博士后研究期间持续参与 Owl 开发，作为核心开发者主导多个子项目，并担任项目负责人。

- **计算图与内存优化：**参与设计计算图抽象（将计算的定义与执行分离，支持惰性求值、图优化与编译），主导其上的图级内存复用：CPU 实验中，相较未启用图优化的执行方式，Mask R-CNN（经典的图像实例分割深度网络）推理内存降低 86.6%、用时降低 24.2%（含建图开销）。
- **模型转换：**主导开发 owl_symbolic，将 Owl 计算图导出为 ONNX 模型，并使用 ONNX Runtime 验证导出模型；另开发 Owl → TensorFlow 计算图转换工具。
- **数值算子：**实现卷积系列 C 算子并做参数自动调优；在 ARM 平台的卷积测试中，性能与 TensorFlow 当时在 CPU 上使用的 Eigen 实现相当。
- **部署与多后端：**主导 Zoo 部署框架，支持 JavaScript 与 MirageOS unikernel 等后端；探索 GPU/TPU 执行（ICFP OCaml Workshop 2019 报告）。
- **项目负责：**主持项目发展与社区，负责代码审查与 CI/CD，获 OCaml 软件基金会两项资助；GitHub 1.3k+ star。主导官方教程编写，合著 Apress、Springer 专著各一部；博士论文围绕 Owl 展开。

北京理工大学 2021.02–2023.04

博士后（合作导师：刘驰教授，长江学者特聘教授、IEEE Fellow）· 边缘智能与工业 AI

- **工业互联网大数据湖（国家重点研发计划课题，核心骨干）：**课题面向异构工业互联网的云–边数据与模型系统。参与其中的迁移学习异常检测研究，面向目标域标注稀缺的场景（如工业质检）做跨域表示对齐，成果以通讯作者发表于 IEEE TKDE 2023（CCF-A）。
- **编译与算子优化：**基于 TVM 的跨平台深度学习编译（cost model 预训练）；边缘设备算子性能自动调优。
- **边缘智能研究（与北理工团队持续合作至今）：**研究边缘侧分布式与联邦学习的同步与资源优化、面向群智感知的多智能体强化学习；以第一或通讯作者在 TMC、TSC、ICDE、TITS、JSTSP 等期刊 / 会议发表论文；作为核心骨干参与国家自然科学基金重点项目等；4 项中国发明专利（第一发明人）。

KnowledgeBase：法律知识库与 Agent 系统 独立从零构建 · 头部律所试用中 · 试用反馈可应要求提供 2026–至今

- 从零完成设计、开发与 AWS 部署：后端知识库采用 RAG 混合检索与多阶段召回，并构建多层级知识图谱；设计 MCP 工具服务（检索、关联、时间线、对比、引用等 7 个工具），由大模型 Agent 自主调用完成多步检索与分析，前端采用 LibreChat（其 Agent 框架基于 LangGraph），并按律师反馈持续迭代。
- **分层检索设计评估：**概率仿真（固定规模、五档相关密度）显示，在相同 90% 平均召回下，多层级分层检索方案较平铺检索减少约 32%–77% 的模拟查询 token 预算。

教育背景

剑桥大学（University of Cambridge） 计算机科学 博士 2015.10–2021.01

导师：Jon Crowcroft 教授（英国皇家学会院士、皇家工程院院士、IEEE/ACM Fellow）；国家留学基金委（CSC）全额奖学金

北京理工大学 软件工程 工程硕士 2013.09–2015.07

北京理工大学 软件工程 学士 2009.09–2013.07

专业技能

- **实践经验：**LLM 推理性能剖析与优化（PyTorch、Nsight Systems / Compute、CPU/GPU 流水重叠、GPU 并发评估）；C 语言数值算子；计算图与内存优化
- **原理理解：**vLLM、SGLang 等推理系统的原理及设计（PagedAttention、RadixAttention 等）；熟悉主流推理优化方法（prefill/decode 调度、设备内算子重叠、投机解码、量化等）
- **AI 辅助研发：**设计并实践多 Agent 协同的研发流程（角色分离、里程碑门控、证据追溯）；熟练使用 Claude Code、ChatGPT 等 AI 编程工具
- **编程与工具：**Python、C、OCaml、MATLAB；PyTorch、Docker、AWS
- **认证与语言：AWS 解决方案架构师（专业级）**、NVIDIA 生成式 AI LLM 认证；英语：科研与授课工作语言

精选成果

- **论文：**25+ 篇，含 7 篇 CCF-A（5 篇为第一或通讯作者）。代表作：
  - **IEEE TMC 2026**（CCF-A，通讯作者）：无人机与地面车辆协同群智感知的多智能体强化学习
  - **IEEE TSC 2022**（CCF-A，第一作者）：边缘联邦学习的异构感知概率同步并行
  - **IEEE JSTSP 2023**（第一作者）：B5G 物联网中并行且内存高效的分布式边缘学习
  - **ICMLC 2025**（第二作者）：基于模型特定 cost model 预训练的跨平台深度学习编译
- **著作：**英文专著 4 部：自动驾驶专著（Wiley，2026）、Owl 相关专著 2 部（Apress、Springer）、企业数据分析专著（Springer）；另参编中文教材 1 部
- **项目与专利：**主持国家自然科学基金青年项目，入选国家博士后国际交流计划引进项目；多项国家级项目核心骨干；4 项中国发明专利（第一发明人）、6 项软件著作权；iENA 金奖（2025，团队获奖：面向智慧城市的空地协同移动群智感知系统与方法）